
Vizuelno prepoznavanje govora pomoću AV-HuBERT modela

Mašinsko učenje
Marko Mrđa · jun 2026.


Cilj

- ▶ Razumeti šta je vizuelno prepoznavanje govora
- ▶ Upoznati arhitekturu modela AV-HuBERT (audio + video)
- ▶ Razumeti tok samonadgledane obuke: klasterizacija i maskirana predikcija
- ▶ Koja je ciljna funkcija i šta model njome uči
- ▶ Videti kako se model fino podešava (fine-tuning) i koliko je uspešan

Uvod i motivacija


Šta je vizuelno prepoznavanje govora

- ▶ Čitanje sa usana: prepoznavanje izgovorenog iz pokreta usana, bez zvuka
- ▶ Vizuelni signal dopunjava sluh i pomaže u buci
- ▶ Homofeme: glasovi p / b / m izgledaju isto na usnama
- ▶ Zato je neophodan vremenski kontekst, a ne pojedinačni kadar



Problem: zavisnost od označenih podataka


- ▶ Najbolji raniji model (Makino, 2019) treniran je na 31.000 h označenih snimaka
- ▶ Označavanje je skupo i nedostupno za većinu od ~7.000 jezika
- ▶ AV-HuBERT uči samonadgledano, iz neoznačenih snimaka
- ▶ Sa samo 30 h označenih podataka postiže bolji rezultat (WER 32,5%)



Pozadina – HuBERT

HuBERT: osnova modela

- ▶ Samonadgledani razvojni okvir za govor (Hsu i dr., 2021)
- ▶ Korak 1: klasterizacija obeležja (k-means) → diskretne ciljne promenljive
- ▶ Korak 2: maskirana predikcija ciljevnih promenljivih (po uzoru na BERT)
- ▶ Naizmenično ponavljanje poboljšava i klustere i reprezentacije




Ponavljanjem ova dva koraka kvalitet klastera i reprezentacija raste.

AV-HuBERT proširuje ovu ideju na audio + video

Arhitektura AV-HuBERT modela


Pregled arhitekture

- ▶ Dva modaliteta: niz slika usana + akustična obeležja
- ▶ Lagani ulazni ekstraktori obeležja: ResNet (video), linearni sloj (audio)
- ▶ Fuzija → deljeni Transformer enkoder
- ▶ Izlaz: predikcija multimodalnih ID-jeva klastera




Ekstraktori obeležja i fuzija

- ▶ Video: modifikovani ResNet-18 nad regionom usana (ROI)
- ▶ Audio: log-mel obeležja kroz samo jedan linearni sloj
- ▶ Fuzija konkatencijom po kanalima: f^{av}
- ▶ Konfiguracije: BASE (103M) i LARGE (325M parametara)



Iterativno generisanje ciljeva

- ▶ Prva iteracija: ciljna obeležja iz MFCC obeležja (k-means)
- ▶ Naredne iteracije: k-means nad obeležjima samog AV-HuBERT-a
- ▶ Ukupno 5 iteracija – kvalitet klastera postepeno raste
- ▶ Multimodalni klasteri su kvalitetniji od jednomodalnih



Obuka i ciljna funkcija

Strategije tokom obuke

- ▶ Maskiranje zamenom: maskirani okviri se menjaju lažnim segmentima
- ▶ Audio i video se maskiraju nezavisno (verovatnoće m_a , m_v)
- ▶ Modality dropout: nasumično izostavljanje celog modaliteta
- ▶ Premošćava jaz: obuka koristi audio+video, a čitanje sa usana samo video


A) Maskiranje zamenom



maskirani okviri se zamenjuju segmentima iz drugog dela videa

→ model prvo mora da prepozna lažne okvire

B) Modality dropout



model ne sme da se osloni samo na audio

Audio i video se maskiraju nezavisno (verovatnoće m_a , m_v);
veća maska na video stream-u jača učenje vizuelnih obeležja

Modality dropout premošćava razliku:
obuka (A+V) → fino podešavanje (samo V)

Ciljna funkcija

- ▶ Maskirana predikcija ID-jeva klastera (unakrsna entropija)
- ▶ Gubitak se računa nad maskiranim okvirima $M^a \cup M^v$
- ▶ α kontroliše doprinos nemaskiranih okvira (u radu $\alpha = 0$)
- ▶ Model uči kontekst i jezičku strukturu, ne samo lokalni izgled

$$p_t = \text{Softmax}(We_t + b)$$

raspodela verovatnoće nad ID-jevima klastera za okvir t

$$L = - \sum_{t \in M^a \cup M^v} \log p_t(z_t) - \alpha \sum_{t \notin M^a \cup M^v} \log p_t(z_t)$$

maskirani okviri

nemaskirani (težina α)

Fine-tuning za prepoznavanje

- ▶ Prethodno obučen enkoder + glava za konkretan zadatak
- ▶ CTC gubitak: poravnanje bez eksplicitne segmentacije
- ▶ Seq2seq gubitak: autoregresivni dekodler generiše tekst
- ▶ Za čitanje sa usana koristi se samo video ulaz

CTC

$$p_t = \text{Softmax}(W^{ft} e_t + b^{ft})$$

$$L_{ctc} = -\log \sum_{\pi \in \mathcal{B}^{-1}(w)} p(\pi | e_{1:T})$$

sabira sva poravnanja π za izlaz w

Seq2seq (S2S)

$$L_{s2s} = -\sum_{l=1}^s \log p(w_l | w_{1:l-1}, e_{1:T})$$

dekoder autoregresivno generiše tekst


(unakrsna entropija po tokenima)

$e_{1:T}$ — reprezentacije prethodno obučenog AV-HuBERT-a

Robusni AVSR – drugi rad


Robusno audio-vizuelno prepoznavanje

- ▶ Isti AV-HuBERT enkoder + novi Transformer dekodler (seq2seq)
- ▶ Obuka uz dodavanje šuma i u pre-obuci i u finom podešavanju
- ▶ Tipovi šuma: govor, žagor, muzika, prirodni zvuci
- ▶ Video deluje kao razdvajanje izvora → robusnost u buci



Ključni rezultati

- ▶ Čitanje sa usana: 32,5% WER sa 30 h (raniji SOTA 33,6% sa 31.000 h)
- ▶ Uz self-training: 26,9% WER na LRS3
- ▶ ASR: 1,3% WER — relativno smanjenje od ~40% u odnosu na raniji SOTA
- ▶ Robusno AVSR: do ~50% niži WER u uslovima šuma



Zaključak

- ▶ AV-HuBERT: samonadgledano učenje audio-vizuelnih govornih reprezentacija
- ▶ Iskorištava prirodnu korelaciju zvuka i pokreta usana
- ▶ Ciljna funkcija: maskirana predikcija multimodalnih klastera
- ▶ Postiže SOTA u čitanju sa usana uz $\sim 1000\times$ manje označenih podataka
- ▶ Proširenja: robusno AVSR, niskoresursni jezici, poboljšanje govora

Reference

- ▶ Shi, B., Hsu, W.-N., Lakhotia, K., Mohamed, A. (2022). Learning Audio-Visual Speech Representation by Masked Multimodal Cluster Prediction. ICLR 2022. arXiv:2201.02184.
- ▶ Shi, B., Hsu, W.-N., Mohamed, A. (2022). Robust Self-Supervised Audio-Visual Speech Recognition. arXiv:2201.01763.
- ▶ Hsu, W.-N. i dr. (2021). HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. arXiv:2106.07447.
- ▶ Makino, T. i dr. (2019). Recurrent Neural Network Transducer for Audio-Visual Speech Recognition. Interspeech.

Dodatni slajdovi

Detalji obuke

Stavka	Vrednost
Skup za pre-obuku	LRS3 (433 h) + VoxCeleb2-En (1.326 h)
Vizuelni ekstraktor obeležja	modifikovani ResNet-18 (region usana)
Audio ekstraktor obeležja	linearni sloj nad log-mel obeležjima
Iteracije klasterizacije	5
BASE / LARGE	12 / 24 Transformer bloka (103M / 325M param.)
α (težina nemaskiranih)	0

Puni rezultati – čitanje sa usana (LRS3)

Metoda	Označeni (h)	Neoznačeni (h)	WER %
Makino i dr. (2019)	31.000	–	33,6
AV-HuBERT BASE	30	1.759	46,1
AV-HuBERT LARGE	30	1.759	32,5
AV-HuBERT LARGE	433	1.759	28,6
AV-HuBERT + self-training	433	1.759	26,9