

Vizuelno prepoznavanje govora pomoću AV-HuBERT modela

Finalni izveštaj

Marko Mrđa · Mašinsko učenje 2 · FTN, Univerzitet u Novom Sadu · 2026

1. Uvod

Vizuelno prepoznavanje govora (engl. Visual Speech Recognition, VSR), poznato i kao čitanje sa usana, jeste zadatak prepoznavanja izgovorenog teksta isključivo iz pokreta usana govornika, bez zvučnog signala. Za razliku od klasičnog prepoznavanja govora, ovde model raspolaže samo nizom slika regiona usana kroz vreme.

Problem je značajan iz više razloga. Vizuelni signal dopunjava sluh i posebno je koristan u bučnim uslovima, gde je zvuk degradiran. Ima primenu u tehnologijama za osobe sa oštećenim sluhom, u prepoznavanju govora sa nemih snimaka, kao i u multimodalnim sistemima gde kombinovanje audio i video modaliteta povećava robusnost.

Ključni izazov su različiti glasovi (na primer p, b, m) koji izgledaju gotovo identično na usnama. Zbog toga jedan kadar nije dovoljan. Neophodan je vremenski kontekst da bi se razrešila višeznačnost. Drugi izazov je zavisnost od velikih količina označenih podataka: raniji pristupi zahtevali su desetine hiljada sati transkribovanih snimaka, što je skupo i nedostupno za većinu od oko 7000 svetskih jezika.

AV-HuBERT rešava drugi problem samonadgledanim učenjem audio-vizuelnih reprezentacija. Iz velike količine neoznačenih snimaka uči opšte reprezentacije govora, a zatim se uz vrlo malo označenih podataka prilagođava konkretnom zadatku. U originalnom radu, sa svega 30 sati označenih podataka postiže se bolji rezultat (WER 32,5%) nego kod ranijih modela obučanih na 31.000 sati.

Cilj ovog rada je:

- (1) analizirati arhitekturu i ciljnu funkciju AV-HuBERT modela,
- (2) reprodukovati proceduru fine-tuninga na podskupu baze podataka radi provere da kod ispravno radi i uvida u samu implementaciju, i
- (3) prilagoditi model na srpski jezik (AI-SPEAK) primenom LoRA adaptacije, uz analizu uticaja različitih konfiguracija.

2. Metode i materijali


2.1 Model - arhitektura AV-HuBERT

AV-HuBERT je proširenje HuBERT okvira (samonadgledano učenje reprezentacija govora) na dva modaliteta: niz slika regiona usana (video) i akustična obeležja (audio). Model čine tri celine: dva modalitetu-specifična ekstraktora obeležja, mehanizam fuzije, i deljeni Transformer enkoder. Ulazni video i audio usklađeni su na frekvenciju od 25 kadrova u sekundi.

- **Video ekstraktor:** modifikovani ResNet-18 nad regionom usana (ROI) dimenzija 96×96 piksela u sivim tonovima. Modifikacija je u ulaznom sloju: umesto standardne 2D konvolucije koristi se 3D konvolucija (kernel $5 \times 7 \times 7$, jedan ulazni kanal, korak $1 \times 2 \times 2$),

praćena batch-normalizacijom, PReLU aktivacijom i 3D max-pooling slojem. Nakon ovog „stem“ sloja sledi standardni 2D ResNet-18: četiri stepena po dva rezidualna bloka, sa brojem kanala $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ — koji se završava globalnim usrednjavanjem. Izlaz je vektor dimenzije 512 po kadru. Ekstraktor ima oko 11,6 miliona parametara.

- **Audio ekstraktor:** jedan linearni sloj nad naslaganim log-mel obeležjima. Iz zvuka se na svakih 10 ms izdvaja 26-dimenzioni vektor log-mel obeležja; četiri uzastopna takva vektora se slažu u jedan (dimenzija $104 = 26 \times 4$), čime se frekvencija zvuka svodi na 25 Hz radi usklađivanja sa videom. Linearni sloj projektuje ovaj vektor u dimenziju modela. Ekstraktor ima svega oko 80 hiljada parametara i namerno je malog kapaciteta, kako zvuk ne bi dominirao nad vizuelnim modalitetom.
- **Fuzija:** konkatencija se vrši po kanalima izlaznih vektora dva ekstraktora, pri čemu je svaki prethodno projektovan u dimenziju 768. Spajanjem nastaje vektor dimenzije 1536, koji se linearnom projekcijom vraća na dimenziju modela (768). Fuzija se dešava pre enkodera, tako da enkoder radi nad jedinstvenom, združenom audio-vizuelnom reprezentacijom.
- **Transformer enkoder:** deljeni enkoder nad združenom reprezentacijom. Korišćena je BASE konfiguracija: 12 blokova, dimenzija modela 768, 12 glava pažnje, dimenzija feed-forward sloja 3072, i ima ukupno oko 103 miliona parametara. (LARGE konfiguracija ima 24 bloka, dimenziju 1024 i ~325 miliona parametara; nije korišćena zbog ograničenja resursa.)
- **Modality dropout:** tehnika regularizacije tokom pretreninga. Sa verovatnoćom 0,5 se ceo jedan modalitet poništi pre fuzije, a kada do toga dođe, sa verovatnoćom 0,5 se bira koji se izostavlja (audio ili video). Time se sprečava da se model osloni isključivo na jedan, lakši modalitet i jača se vizuelni enkoder, što je preduslov za kasnije čitanje sa usana samo iz videa.



Slika 1. Pregled arhitekture AV-HuBERT modela: ekstraktori obeležja → fuzija → Transformer enkoder → predikcija klastera maskiranih kadrova. (Izvor: Shi i dr., 2022.)

2.2 Obuka i ciljna funkcija

- **Faza 1 — Pretrening (samonadgledano učenje).** Cilj je da model nauči opšte audio-vizuelne reprezentacije govora iz velike količine neoznačenih snimaka, kroz ciklus klasterizacije i maskirane predikcije. Svakom kadru se dodeljuje diskretni identifikator klastera (pseudo-oznaka) pomoću k-means algoritma: u prvoj iteraciji klasteri se računaju iz MFCC obeležja, a u kasnijim iteracijama iz sve boljih obeležja samog modela. Postupak se ponavlja kroz 5 iteracija, pri čemu raste i broj klastera (od 100 do 2000), čime pseudo-oznake postaju sve kvalitetnije. Zatim se deo kadrova maskira (nasumično se biraju početni kadrovi i maskira se niz koji sledi), a model predviđa identifikator klastera maskiranih kadrova — analogno BERT-ovom zadatku popunjavanja praznina, ali nad diskretizovanim govorom. Ciljna funkcija maskirane predikcije klastera je:

$$L = - \sum_{t \in M^a \cup M^v} \log p_t(z_t) - \alpha \sum_{t \notin M^a \cup M^v} \log p_t(z_t)$$

gde je M skup maskiranih kadrova, z_t identifikator klastera kadra t , a p_t predviđena raspodela nad K klastera. Logiti se računaju kosinusnom sličnošću između izlaza enkodera i naučenih klaster-embeddinga. Težina nemaskiranih kadrova (α) je u praksi nula jer model se uči isključivo na maskiranim kadrovima. Korišćeni model je BASE, pretreniran na bazama LRS3 i VoxCeleb2.

- **Faza 2 — Fine-tuning (nadgledano učenje).** Za razliku od faze 1, ovde se koriste označeni podaci, parovi (video, tekst). Na pretrenirani enkoder dodaje se Transformer dekodera, čime nastaje sekvenca-u-sekvencu (seq2seq) arhitektura, dok se pretraining glava za predikciju klastera uklanja. Dekoder je autoregresivan: generiše transkript token po token, sleva nadesno, pri čemu svaki sledeći token zavisi od prethodno generisanih tokena (kroz maskiranu samopažnju) i od izlaza enkodera (kroz ukrštenu pažnju nad reprezentacijom usana). Za BASE model dekodera ima 6 slojeva, dimenziju 768 i sopstveni embedding nad ciljnim vokabularom. Predviđaju se delovi reči iz vokabulara napravljenog tokenizatorom SentencePiece nad transkriptima. Ciljna funkcija je unakrsna entropija sa ublažavanjem oznaka (label smoothing 0,1): tačan token u cilju dobija verovatnoću 0,9 umesto 1,0, a preostalih 0,1 se raspodeljuje na ostale tokene, čime se sprečava preterana samouverenost modela. Tokom obuke koristi se “teacher forcing”: dekodera se kao ulaz daju tačni prethodni tokeni umesto sopstvenih predikcija, pa se cela sekvenca uči u jednom prolazu. U standardnoj proceduri enkoder se prvih N koraka drži zamrznutim, pa se odmrzava. Pri evaluaciji se transkript generiše pretragom snopom (beam search): umesto da se na svakom koraku uzme samo najverovatniji token, istovremeno se prati više kandidat-sekvenci i bira ona sa najvećom ukupnom verovatnoćom.

2.3 LoRA adaptacija

Za prilagođavanje na “AI SPEAK” korpus, koji sadrži malu količinu podataka iskorišćena je LoRA (Low-Rank Adaptation): pretrenirani slojevi se zamrznu, a u linearne slojeve se ubacuju male niskorangovane matrice A i B , tako da je izlaz $W \cdot x + (\alpha/r) \cdot B(A \cdot x)$. Obučavaju se samo A i B (rang r je mali), dok W ostaje zamrznut. Time se broj obučavanih parametara drastično smanjuje, čime se smanjuje i rizik od preprilagođavanja (overfitting) na malim skupovima.

Matrica B se inicijalizuje na nulu, pa je na početku obuke dodatak $(\alpha/r) \cdot B(A \cdot x)$ jednak nuli, te dobijamo izlaz koji je identičan pretreniranom modelu. Obuka time kreće od stabilne, pretrenirane tačke, a adapter uči odstupanja tek kako se B menja.

Adapteri su uvedeni u projekcije upita i vrednosti (q_proj , v_proj) unutar slojeva pažnje. Razmatrana su dve varijante: „samo dekođer“ (adapteri u q_proj/v_proj svih slojeva dekođera, oko 590 hiljada obučavanih parametara, 0,37% modela) i „enkoder+dekođer“ (adapteri se dodatno uvode i u projekcije pažnje enkodera). Svi ostali parametri (video ResNet, audio projekcija, fuzija, telo enkodera i dekođera) ostaju zamrznuti. LoRA je implementirana direktno u kodu modela, jer verzija fairseq-a iz 2021. nema ugrađenu podršku: ciljni linearni slojevi se pri izgradnji modela zamenjuju svojim LoRA verzijama. Ta izmena se uključuje kroz konfiguraciju.

2.4 Podaci

Korišćena je baza LRS3-TED (rečenice iz TED/TEDx govora, engleski jezik), ista baza na kojoj se AV-HuBERT ocenjuje u originalnom radu. Zbog ograničenih resursa i cilja rada (provera ispravnosti koda, a ne potpuna reprodukcija), korišćen je podskup:

- Obuka (train): 3.000 klipova; validacija: 200 klipova (iz trainval podskupa).
- Test: kompletan zvanični test skup — 1.321 iskaz.

Pretprocesiranje LRS3: detekcija lica i 68 tačaka (dlib) → isecanje ROI usana na 96×96 → audio na 16 kHz → manifesti (.tsv), transkripti (.wrd) i *SentencePiece* vokabular veličine 1000.

AI-SPEAK korpus (srpski). Bilingvalna baza: 30 govornika (15 muških, 15 ženskih). Korišćen je srpski deo: oko 2.375 iskaza $\approx$ ~2,7 sata govora. Video: frontalna kamera 100 fps, rezolucija 1080×1920 , anonimizovano. Audio je 22,05 kHz mono, koji se u pretprocesiranju prevodi u 16 kHz po zahtevima modela.

Pretprocesiranje AI-SPEAK-a razlikuje se od LRS3, pre svega zbog anonimizacije snimaka, na sledeće načine:

- Isecanje regiona usana (bez dlib-a). Standardna dlib detekcija lica otkazuje na anonimizovanim snimcima (na oko 50% govornika), jer je gornji deo lica maskiran. Umesto nje, pošto je kadar pretežno crn, lice se pronalazi kao svetli region (skup ne-crnih piksela), a zatim se iseca kvadrat centriran na usta i skalira na 96×96 piksela u sivim tonovima.

- Sečenje na govorni deo. Originalni klipovi su neisečeni (sadrže tišinu i šum na krajevima), pa se pomoću priloženih poravnjanja video i audio seku na sam iskaz kao što je urađeno kod LRS3 klipova.

- Novi srpski vokabular. Napravljen je zaseban SentencePiece vokabular veličine 500 iz srpskih transkripta.

- Podela disjunktna po govornicima. Train: spk01–23, valid: spk24–26, test: spk27–30. Test govornici se nikada ne pojavljuju u obuci, čime se meri generalizacija na nove osobe.

2.5 Eksperimentalna postavka

- Hardver: iznajmljen GPU NVIDIA A40 na platformi RunPod. Pretprocesiranje je rađeno lokalno (CPU), a na GPU-u samo obuka.
- Konfiguracija obuke. Obuka koristi fp16 preciznost i trofazni raspored stope učenja sa fazom zagrevanja. Zbog ograničene memorije GPU-a, efektivni batch se postiže akumulacijom gradijenta. Stopa učenja je 0.003. Ostali parametri po skupovima:
 - LRS3 (provera toka): max_tokens = 1500, update_freq = 2, warmup = 1000 koraka, ukupno max_update = 3000 koraka.
 - AI-SPEAK (LoRA): max_tokens = 2000, update_freq = 4, warmup = 400 koraka; LoRA rang $r = 16$ (izabran na validaciji), alpha = 16, dropout 0.05, na projekcijama pažnje q_proj i v_proj .
- Modalitet: samo video (VSR). Model čita isključivo pokrete usana, audio se ne koristi ni u obuci ni u testu, jer je zadatak vizuelno prepoznavanje govora.
- Metodologija: Test skup je fiksiran unapred i ne koristi se pri izboru parametara. Rang LoRA ($r \in \{4, 8, 16, 32\}$) biran je isključivo na validacionom skupu. Zaustavljanje se vrši po pravilu maksimalnog broja koraka uz rano zaustavljanje. Sa izabranim rangom $r = 16$ urađene su dve finalne postavke na test skupu — LoRA samo na dekoderu i LoRA na enkoderu+dekoderu. Polazni enkoder je pretrrenirani BASE.
- Metrika: WER (Word Error Rate).

3. Rezultati

3.1 LRS3 podskup — provera ispravnosti toka

Pre srpske adaptacije, ceo tok (pretprocesiranje → obuka → dekodiranje → WER) proveren je na malom podskupu LRS3 (3.000 klipova, 3.000 koraka; test 1.321 iskaz). Cilj je bio potvrda ispravnosti implementacije:

Eksperiment	Obučavani parametri	WER (test)
Puni fine-tuning	161M (100%)	74,4%
LoRA (dekoder q/v)	294.912 (0,18%)	93,6%

WER je očekivano visok u odnosu na 26–32% iz rada (150× manje podataka, 10× kraća obuka). Tok je potvrđen kao ispravan, a LoRA implementacija validirana pre prelaska na srpski.

3.2 AI-SPEAK — adaptacija na srpski jezik

Glavni deo rada je adaptacija AV-HuBERT modela na srpski jezik primenom LoRA adaptacije. Izbor ranga LoRA sproveden je pretragom nad $r \in \{4, 8, 16, 32\}$ sa LoRA na dekodernu, pri čemu je WER meren na validacionom skupu (govornici spk24–26), a test skup (spk27–30) ostaje netaknut. Cilj je izabrati rang r bez ikakvog uvida u test skup.

Rang LoRA (r)	Opseg	Obučavani par.	Validacioni WER (%)
4	samo dekodernu	147K (0,09%)	77,8
8	samo dekodernu	295K (0,18%)	76,4
16	samo dekodernu	590K (0,37%)	71,0 (r^*)
32	samo dekodernu	1,18M (0,73%)	73,6


3.3 Provera na test skupu

Validacija pokazuje da je rang $r^*=16$ najbolji izbor, te nakon izabranog ranga radimo dve finalne postavke koje su obučene i evaluirane na fiksnom test skupu:

- (1) LoRA samo na dekodernu
- (2) LoRA na enkodernu+dekodernu.

U oba slučaja polazni enkodernu potiče iz modela koji je samonadgledano pretreniran na bazama LRS3 i VoxCeleb2, a zatim fine-tuniran za engleski VSR na označenom delu LRS3 (433h). Engleski dekodernu se odbacuje, a srpski dekodernu i vokabular obučavaju se iznova. Za obe konfiguracije posmatra se test WER.

Finalna konfiguracija	LoRA opseg	Test WER (%)
LoRA — samo dekodernu	dekodernu, $r=16$	74,5
LoRA — enkodernu+dekodernu	enkodernu+dekodernu, $r=16$	73,1



Slika 2. Krive obuke na validacionom skupu ($r=16$) za dve finalne konfiguracije: greška po tokenu (levo) i tačnost (desno).

3.4 Analiza grešaka

Najbolji test WER na srpskom je 73,1% (LoRA enkoder+dekoder, $r=16$), odnosno 74,5% za LoRA samo na dekoderu. Da bi se razumelo šta se iza tog proseka krije, analizirani su izlazni transkripti.

Analiza svih 311 test transkripta pokazuje da prosečan WER sakriva neujednačeno ponašanje modela. Model gotovo savršeno prepoznaje poznate, strukturisane sekvence (brojevi 0–9, dani u nedelji): na iskazima sa tri ili više takvih reči prosečan WER je svega ~7%. Na slobodnim rečenicama rezultat naglo opada: 65% klipova ima manje od 40% tačnih reči, a najduže rečenice se često raspadaju u ponavljanje istog tokena. Model je, dakle, naučio srpsko čitanje sa usana za ograničene, ponovljive iskaze, ali mu za slobodan govor nedostaje podataka.

Primeri predikcija (REF = referentni transkript, HYP = predikcija iz nemog videa):

REF: ponedeljak utorak sreda četvrtak petak subota nedelja

HYP: ponedeljak utorak sreda četvrtak petak subota nedelja (tačno)

REF: nula jedan dva tri četiri pet šest sedam osam devet

HYP: nula jedan dva tri četiri pet šest sedam osam devet (tačno)

REF: istraživanje je obavljeno na slučajnom stratifikovanom uzorku

HYP: istraživanje je je na na stratifikovanom uzorku (delimično)

REF: beograd postaje grad u kome žive sve stariji ljudi

HYP: bilo je je je je uuzzddddd i i i i i i i i (raspad na dužoj rečenici)

4. Zaključak

U radu je analiziran AV-HuBERT model za vizuelno prepoznavanje govora, reprodukovana je procedura fine-tuninga na podskupu LRS3 (provera ispravnosti toka), i model je prilagođen na srpski jezik na korpusu AI-SPEAK putem LoRA adaptacije, uz izbor ranga na validaciji i poređenje dve varijante na neviđenim govornicima. Najbolji rezultat je 73,1% WER. Model pouzdano prepoznaje kratke strukturisane iskaze, ali mu za bolje rezultate na slobodnom govoru nedostaje podataka.

Najvažniji aspekti urađenog:

(1) potvrđeno je da samonadgledani pretrening uz mali fine-tuning daje upotrebljiv sistem za čitanje sa usana;

(2) implementirana je, validirana i primenjena LoRA adaptacija unutar fairseq okvira;

(3) sproveden je izbor ranga LoRA na validacionom skupu, a poređenje dve varijante adaptacije (samo dekodler i enkoder+dekoder) pokazalo je da opseg adaptacije jedva utiče na rezultat.

Glavno ograničenje, ujedno i dominantni faktor kvaliteta, jeste obim označenih srpskih podataka (~2,7 h), a ne arhitektonski izbori: uz jedno pokretanje po konfiguraciji i mali test skup, razlike od nekoliko procentnih poena ostaju unutar šuma. Rezultat bi najviše poboljšalo više označenih srpskih podataka, uz jaču regularizaciju i veću (LARGE) konfiguraciju modela.

Literatura

- [1] Shi, B., Hsu, W.-N., Lakhotia, K., Mohamed, A. Learning Audio-Visual Speech Representation by Masked Multimodal Cluster Prediction. arXiv:2201.02184 (2022).
- [2] Shi, B., Hsu, W.-N., Mohamed, A. Robust Self-Supervised Audio-Visual Speech Recognition. arXiv:2201.01763 (2022).
- [3] Hsu, W.-N. i dr. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. (2021).
- [4] Afouras, T., Chung, J. S., Zisserman, A. LRS3-TED: a large-scale dataset for visual speech recognition. arXiv:1809.00496 (2018).
- [5] Hu, E. i dr. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685 (2021).